VISHUE AR 평가지표 v2.1

팀이 정한 숫자를 없애고, 논문·공개 벤치마크·통계로 근거를 댈 수 있는 합격선만 쓴 평가 기준

AR 파트 전진영 · 2026-11-03 · 측정: 저장소 최신 코드(HEAD 895bae24) 기준 · 자연스러움은 v4 설문(11/2 이전 렌더)

바꾼 원칙 한 줄 — 합격선은 **① 사람 눈 실험으로 정해진 공개 역치, ② 같은 데이터에서 다른 연구가 낸 최고 성능, ③ "우연이 아니다"를 판정하는 통계 검정** 중 하나에서만 가져옵니다. 근거를 댈 수 없는 수치는 합격·불합격을 매기지 않고 **기록만** 합니다.

평가지표 요약

지표	무엇을 재나	합격선	합격선의 근거	현재 값	판정
① 색상일치	AR 입술색과 실제 바른 입술색의 차이 (ΔE2000)	중앙값 **≤ 1.8** + 맨입술보다 가까운 쌍 15/20 이상	사람 50%가 "허용 가능"이라고 답한 색 차이(Paravina 2015). 화면 속 얼굴 피부 실험도 1.81(Lagouvardo 2018)	3.86 맨입술보다 가까움 15/20	판정 불가
② 위치	사람이 칠한 입술 정답과 얼마나 겹치나 (F1)	데이터 전체 F1 **≥ 0.887** (IoU 0.797)	같은 LaPa 데이터의 공개 최고 성능(SegFace, AAAI 2025)	F1 0.840 (IoU 0.724)	불합격
③ 질감·광택	명암 폭·하이라이트·입술 결(SSIM)이 맨입술보다 실제에 가까운가	세 수치 **각각** 20쌍 중 **15쌍 이상**	부호 검정: 우연히 15쌍 이상 나올 확률 2.1% (5% 미만이면 "우연 아님")	8 · 11 · 6 쌍	불합격
④ 자연스러움	사람이 실제와 AR을 구별하나 (블라인드)	맞힌 비율의 90% 범위 위쪽 끝 **< 60%**, 판단 **194개 이상** + 점수 차 효과크기 < 0.2	AI 얼굴 판별 연구 설계 (PNAS 2022), 통계 관례상 "작은 효과"(Cohen 1988), 표본 수 계산	86.7% (범위 70~100%) 판단 30개	불합격

판정 단어의 뜻

합격	제대로 잰 값이 근거 있는 합격선을 넘음
불합격	제대로 잰 값이 합격선에 못 미침
판정 불가	잰 값은 있지만 데이터가 판정할 만큼 정확하지 않음
기록만	근거 있는 합격선이 세상에 없음 → 변화만 추적

결론 — 근거 있는 기준으로 다시 재도 **위치·질감·자연스러움은 불합격**입니다. **색은 지금 사진으로는 판정할 수 없습니다**(3쪽). 특히 질감과 자연스러움은 기준 근처가 아니라 크게 떨어져 있어서, 기준을 어떻게 정하든 결론이 바뀌지 않습니다.

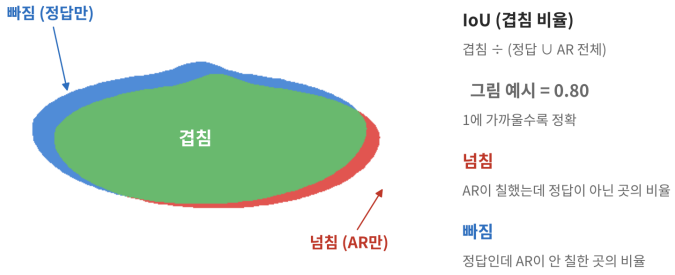
무엇이 바뀌었나 — 팀이 정한 숫자 vs 근거 있는 숫자

v2.0의 측정 **공식**(ΔE2000, IoU, SSIM, 균형 정확도)은 모두 표준이었지만, **합격 숫자**는 대부분 팀이 정한 값이었습니다. 찾아본 범위에서 **AR 메이크업 전용으로 공인된 합격선은 논문·표준 어디에도 없었습니다.** 그래서 아래 세 가지 방법으로만 숫자를 정했습니다.

① 사람 눈 실험값	② 공개 벤치마크	③ 통계 검정
여러 사람이 실제로 보고 "알아챈다 / 받아들인다"고 답한 지점	같은 데이터에서 다른 연구가 낸 최고 성적	"이 결과가 우연일 확률" 5% 미만, 필요한 표본 수는 공식으로 계산

지표	v2.0 (팀이 정함)	v2.1 (근거 있음)	근거 종류
색상	ΔE ≤1.5, 개별 80% 이상	ΔE ≤1.8 + 맨입술보다 나은 쌍 15/20	① 사람 눈 실험 + ③ 부호 검정
위치	IoU ≥0.90 (1차 0.80), 경계 ≤1.5%, 넘침 ≤5%, 빠짐 ≤8%	F1 ≥0.887 + 이전 버전보다 나빠지지 않음. 경계·넘침·빠짐은 **기록만**	② 공개 벤치마크 + ③ 짝지은 비교 검정
질감	2/3 규칙으로 16/20, 결 14/20	세 수치 각각 15/20	③ 부호 검정
자연스러움	정답률 ≤55%, 상한 ≤60%, 점수 ≤1.5, 평가자 20명	90% 범위 위쪽 끝 <60%, 판단 194개 이상, 점수 효과크기 <0.2	③ 동등성 검정 + 표본 수 계산, 연구 설계 참고

IoU 0.90에 대해 — 같은 데이터에서 지금까지 나온 **어떤 연구 모델도 입술 IoU 0.90을 넘지 못했습니다**(최고 약 0.80~0.83, 서버급 모델). 또 사람이 칠한 정답을 입 너비의 1%만 옆으로 옮겨도 IoU가 0.93까지 떨어집니다. 그래서 0.90은 근거를 댈 수 없는 숫자이고, v2.0의 "1차 목표 0.80"이 오히려 공개 최고 성능과 거의 같습니다.

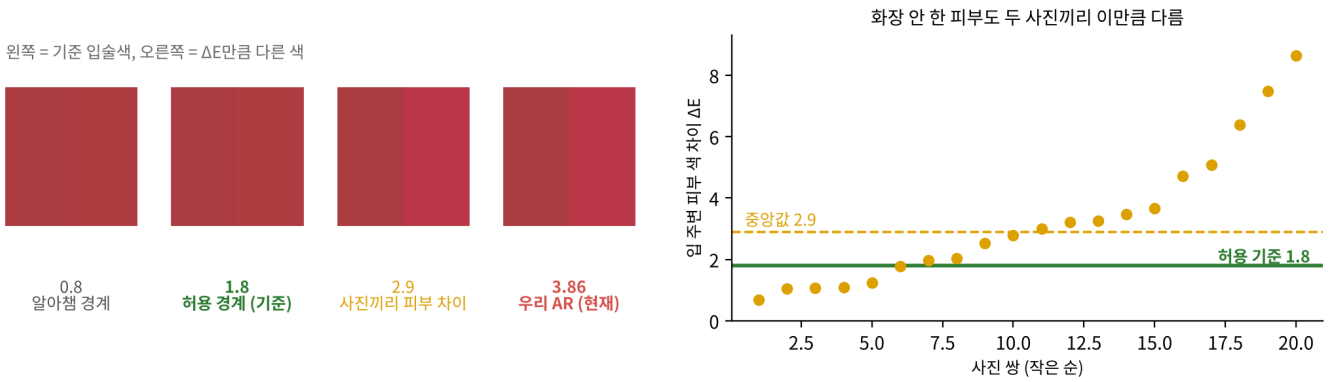


IoU·F1이 무엇을 재는지: 초록 = 겹침, 빨강 = 넘침, 파랑 = 빠짐

F1과 IoU — 논문들은 F1(=Dice)로 보고합니다. 둘은 공식으로 1:1 변환됩니다: IoU = F1 ÷ (2 − F1). 예: F1 0.887 = IoU 0.797. 이 문서는 논문과 같은 방식(데이터 전체 픽셀을 합산)으로 계산했습니다.

① 색상일치 — 기준은 근거가 있지만, 지금 사진으로는 잴 수 없다

합격선 근거
· **ΔE2000 1.8**: 치과 색 역치 국제 공동연구(Paravina 2015). 관찰자 50%가 "이 정도 차이는 받아들인다"고 답하는 지점(허용 역치). 50%가 "차이를 알아챈다"는 지점(인지 역치)은 0.8.
· **교차 확인**: **화면에 띄운 얼굴 피부**로 90명이 판단한 실험(Lagouvardo 2018)에서도 허용 역치가 1.81 (계산식은 ΔE*ab라 정확히 같은 공식은 아님).
· 두 연구 모두 립스틱 실험은 아님 → **공개된 것 중 가장 가까운 기준**으로 사용.



왼쪽: 색 차이가 눈에 어떻게 보이는지 · 오른쪽: 20쌍의 입 주변 피부 색 차이

왜 "판정 불가"인가



주황 = 입 주변 피부 띠(립스틱이 안 닿음), 파랑 = 입술 측정 영역

Kaggle 사진은 맨얼굴과 립 바른 얼굴을 **따로 찍은 사진**입니다. 립스틱이 닿지 않는 **입 주변 피부**를 두 사진에서 비교하면, 화장과 상관없이 **이미 ΔE 2.9** 만큼 다릅니다. 조명·노출이 달랐다는 뜻입니다.

합격선(1.8)보다 사진끼리의 차이(2.9)가 더 크니, AR이 완벽해도 이 사진으로는 1.8 아래가 나오기 어렵습니다. 그래서 **"불합격"이 아니라 "판정 불가"**입니다. 자로 재려는 길이보다 자의 눈금이 더 굵은 상황입니다.

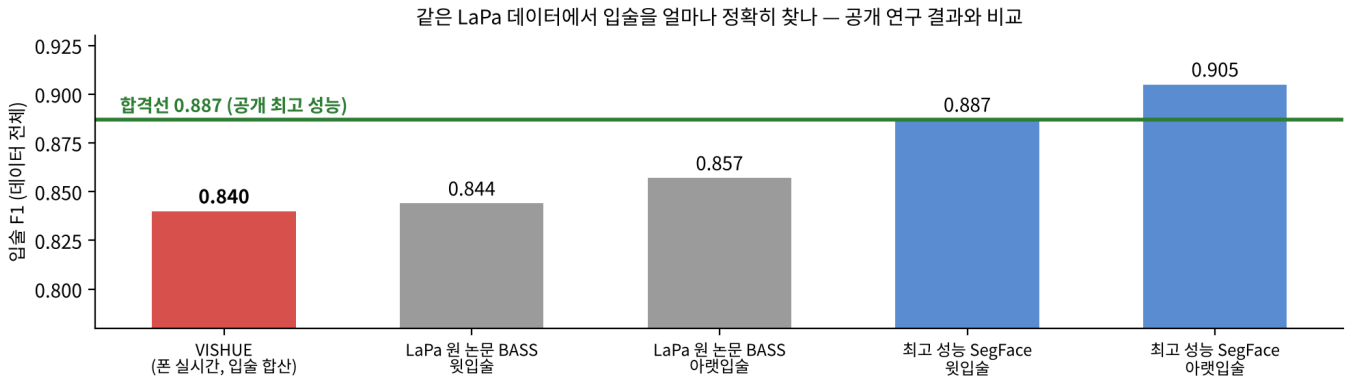
판정 조건(코드에 들어감): 피부 바닥값 < 1.8일 때만 색 합격·불합격을 매깁니다.

측정	값	기준	판정
AR 입술 색 차이 중앙값 (20쌍)	3.86	≤1.8	판정 불가
AR이 맨입술보다 실제에 가까운 쌍 (부호 검정)	15/20 (p = 0.021)	≥15/20	합격
입 주변 피부 바닥값 (판정 가능 조건)	2.90	<1.8	조건 미달

판정 가능하게 하려면 — 같은 사람·같은 자리에서 **노출·화이트밸런스를 고정**하고 **컬러 체커**를 함께 찍은 맨얼굴/립 사진 쌍. 촬영 후 피부 바닥값이 1.8보다 충분히 작은지 먼저 확인합니다.

② 위치 — 공개 최고 성능과 비교

합격선 근거 — **LaPa**는 사람이 얼굴 부위를 픽셀 단위로 칠해 둔 공개 연구 데이터입니다. 여러 연구가 이 데이터로 성적을 발표했고, 가장 최근 최고 성능(SegFace, AAAI 2025)의 입술 F1은 **윗입술 88.7~88.8, 아랫입술 90.5**입니다. 이 중 낮은 값 **0.887**을 합격선으로 씁니다. "공개된 최고 모델 수준에 도달했나"를 묻는 기준입니다.



VISHUE는 LaPa 시험용 사진 1,840장 기준. 다른 연구는 같은 시험용 2,000장 기준(논문 표)

측정	값	기준	판정
입술 F1 (데이터 전체 합산, 윗+아랫입술 합침)	0.840 (IoU 0.724)	≥0.887	불합격
이전 버전보다 나빠지지 않음 (짝지은 비교 검정)	—	$p \geq 0.05$	미측정
사진별 IoU 평균 · 경계 오차 · 넘침 · 빠짐	0.705 · 1.4% · 16.1% · 19.4%	근거 없음	기록만

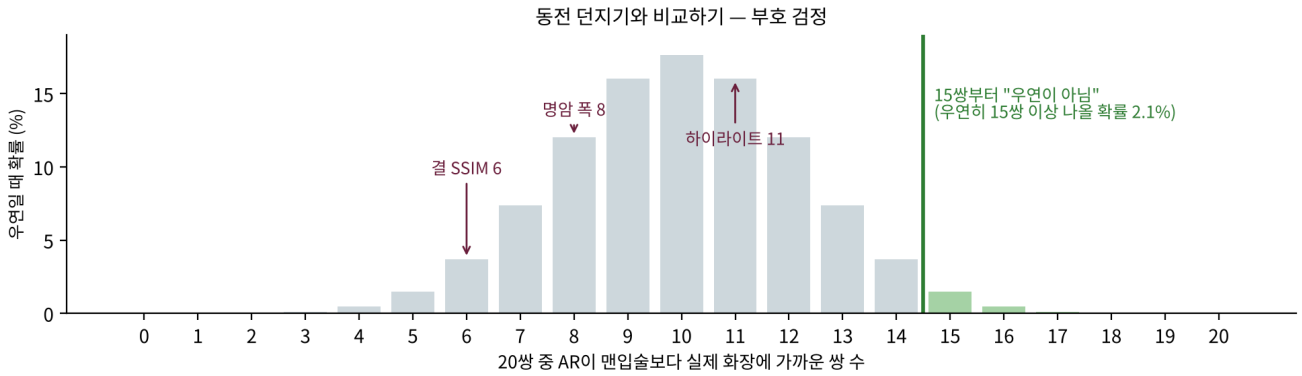
읽는 법

- VISHUE(0.840)는 **LaPa를 만든 연구팀의 2020년 모델(BASS 0.844 · 0.857)과 비슷한 수준**이고, 최신 최고 성능보다는 약 0.05 낮습니다.
- VISHUE는 **폰에서 실시간**으로 얼굴 점 478개만 쓰고, 비교 대상은 **서버에서 448~512px로** 돌리는 분할 모델입니다. 같은 조건의 비교가 아니므로 "근사 비교"로 봅니다.
- VISHUE는 윗입술과 아랫입술을 **합쳐서** 채점합니다. 합치면 두 입술 사이 경계 오차가 사라져 점수가 오르는 쪽이고, 실패하기 쉬운 사진 160장(입술이 너무 작음 · 얼굴 못 찾음)도 빠져 있습니다. **그래도 못 미치므로 불합격 결론은 확실**합니다. 반대로 나중에 0.887을 넘었을 때는 이 두 이유로 약간 유리하게 나온 값일 수 있습니다.
- **회귀 방지**: AR을 고친 뒤 같은 사진들로 다시 재서, 사진별 IoU가 이전보다 통계적으로 낮아졌으면(윌콕슨 검정 $p < 0.05$) 불합격입니다. 숫자를 정할 필요가 없는 기준입니다. 이전 버전 결과 파일이 있어야 판정됩니다.

경계 오차·넘침·빠짐은 v2.0에서 1.5%·5%·8%를 합격선으로 썼지만, 이 숫자를 뒷받침하는 논문이 없어 **기록만** 합니다. 사람이 "경계가 어색하다"고 느끼는 지점을 설문으로 재면 그때 근거 있는 합격선이 생깁니다.

③ 질감·광택 — "맨입술보다 확실히 낫나"를 통계로

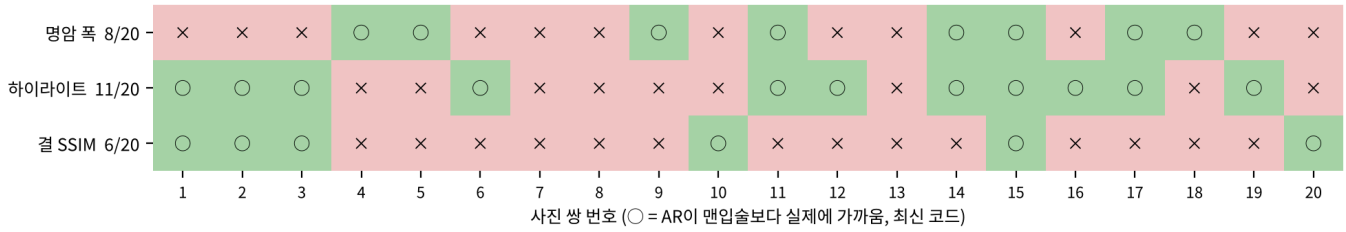
질감은 색처럼 공인된 역치가 없습니다. 대신 **같은 사진의 맨입술**을 비교 기준으로 둡니다. AR을 입혔으면 적어도 아무것도 안 바른 입술보다는 실제 화장에 가까워야 합니다. 문제는 "몇 쌍 이상이면 확실히 낫다고 할 수 있나"인데, 이것을 **부호 검정**으로 정합니다.



AR이 아무 효과가 없으면 20쌍 중 이기는 쌍 수는 동전 20번 던져 앞면 나오는 수와 같습니다

쉽게 말하면 — 동전을 20번 던져 앞면이 15번 이상 나올 확률은 2.1%입니다. 그래서 AR이 20쌍 중 **15쌍 이상**에서 이기면 "우연이 아니라 진짜 낫다"고 말할 수 있습니다(과학에서 쓰는 기준: 우연일 확률 5% 미만). 14쌍이면 우연일 확률이 5.8%라 부족합니다. **15라는 숫자는 사람이 정한 게 아니라 계산에서 나온 값**입니다.

수치	무엇을 보나
명암 폭	입술의 어두운 곳~밝은 곳 차이 (볼륨감)
하이라이트	가장 밝은 반사의 세기 (광택)
결 SSIM	입술 주름·결 무늬가 같은지 (Wang 2004 표준 지표)

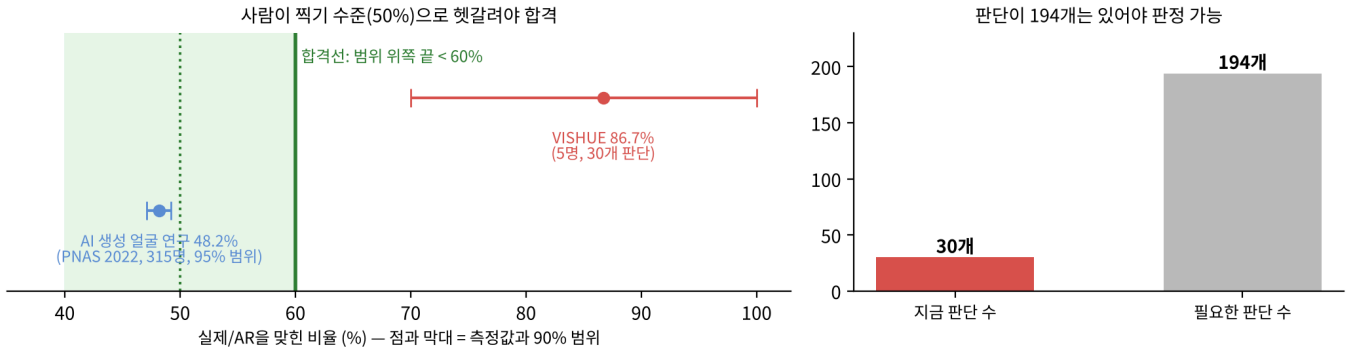


수치	이긴 쌍	우연일 확률	기준	판정
명암 폭	8 / 20	87%	≥15	불합격
하이라이트	11 / 20	41%	≥15	불합격
결 SSIM	6 / 20	98%	≥15	불합격

세 수치 모두 통과해야 합격인 이유 — 여러 수치 중 "하나만 넘으면 합격"으로 하면 우연히 합격할 확률이 커집니다. 모두 통과를 요구하면 그 위험이 생기지 않습니다. 단, **명암 폭·하이라이트는 팀이 설계한 측정 방법**이라, 사람이 느끼는 광택과 얼마나 맞는지는 작은 설문에서만 확인됐습니다(하이라이트 차이가 클수록 "질감 어색" 응답 증가).

④ 자연스러움 — 사람이 찍기 수준으로 헷갈리나

설계 근거 — "AI가 만든 얼굴을 사람이 구별할 수 있나"를 잰 연구(Nightingale & Farid, PNAS 2022)는 315명에게 실제/AI 얼굴 128장씩을 보여 주고 맞힌 비율을 쟀습니다. 결과는 **48.2%**로 찍기(50%)와 다르지 않았고, 이것을 "구별할 수 없다"의 근거로 삼았습니다. VISHUE도 같은 방식(실제 화장 사진과 AR 사진을 1:1로 섞어 블라인드로 맞히기)을 씁니다. 실험 진행 방식은 영상 화질 평가 국제 표준 ITU-T P.910을 따릅니다.



왼쪽: 맞힌 비율과 범위. 초록 영역 안에 범위 전체가 들어와야 합격 · 오른쪽: 필요한 판단 수

숫자가 어디서 나왔나

숫자	근거
60% (범위 위쪽 끝)	통계에서 널리 쓰는 효과크기 관례(Cohen 1988)의 **"작은 효과"(h = 0.2)**가 50% 대비 60%에 해당. "사람이 구별을 하더라도 작은 효과 이하"임을 보이는 기준
194개 (판단 수)	실제 구별 능력이 60%라면 그것을 80% 확률로 잡아낼 수 있는 표본 수(표준 계산식: 유의수준 5%, 검정력 80%). 예: 평가자 20명 × 쌍 사진 10장 = 200개
0.2 (점수 차 효과크기)	같은 관례의 "작은 효과"(d = 0.2). AR 점수가 실제 사진 점수보다 작은 차이 이하로만 낮아야 함
90% 범위	"차이가 없음"을 보일 때 쓰는 동등성 검정(양쪽 5%씩)의 표준 범위. 평가자 단위로 다시 뽑아 계산(같은 사람의 여러 답을 독립으로 보지 않음)

측정 (v4 설문, 평가자 5명)	값	기준	판정
실제/AR 맞힌 비율 (균형 정확도)	86.7% (90% 범위 70~100%)	위쪽 끝 <60%	불합격
점수 차 (실제 4.47 vs AR 1.93) 효과크기	2.21 (범위 1.11~4.81)	위쪽 끝 <0.2	불합격
판단 수	30	≥194	부족

판단 수가 부족한데 왜 "불합격"을 확정하나 — 범위의 **아래쪽 끝(70%)조차 60%보다 높기** 때문입니다. 표본이 적어 범위가 넓어도, 범위 전체가 합격선 밖에 있으면 결론은 바뀌지 않습니다. 반대로 결과가 50% 근처로 나왔는데 판단이 194개보다 적으면 **"판정 불가"**로 처리합니다(우연히 좋게 나왔을 수 있어서).

이 기준을 그대로 써도 되나 — 재검증 결과

1. 근거 수치를 원문과 대조했나

근거	확인 방법과 결과	상태
SegFace LaPa 입술 F1 88.7 / 90.5	논문(arXiv 2412.08647) 표 1(a)에서 직접 확인	확인
BASS(LaPa 원 논문) 84.4 / 85.7	같은 표의 비교 행에서 확인	확인
Paravina 2015 ΔE2000 0.8 / 1.8	이 논문을 인용한 2026년 학술지(RDE) 본문에서 수치·출처 확인. 원문은 접속 차단으로 미열람	간접 확인
Lagouvardo 2018 화면 얼굴 피부 1.81	J-STAGE 초록에서 확인 (90명, 화면 표시, ΔE*ab)	확인
Nightingale 2022 315명, 48.2%	연구 색인 사이트에서 확인. PNAS 원문은 접속 차단	간접 확인
ITU-T P.910 (2026-07)	ITU 사이트에 해당 판 존재 확인	확인

2. 계산을 다시 했나

계산	결과	상태
부호 검정 15/20, 14/20	우연일 확률 2.07%, 5.77% (정확 이항검정, scipy 결과와 대조)	일치
필요 판단 수	h = 0.201 → 194개	일치
F1 ↔ IoU 변환, VISHUE F1	사진별 IoU·면적에서 겹친 픽셀을 복원해 합산: F1 0.8398 (1,840장), 0.8446 (200장)	일치
ΔE2000 계산 코드	국제 표준 검증용 색 쌍(Sharma 2005)과 오차 0.00004	일치
평가 코드	테스트 10개 통과 (항상 같은 답만 누르는 평가자, 표본 부족, 피부 바닥값, 회귀 등)	통과

3. 남는 한계 (숨기지 않고 적음)

지표	한계	사용 판단
색상	역치가 치과 재료·화면 피부 실험에서 온 값(립스틱 아님). **지금 사진은 바닥값 2.9로 판정 불가**	조건부 촬영 후 사용
위치	서버 모델과 폰 실시간 모델의 근사 비교, 입술 합산·사진 160장 제외로 VISHUE에 약간 유리	사용 가능
질감	판정은 통계라 객관적. 단 명암 폭·하이라이트는 팀이 설계한 측정법	사용 가능
자연스러움	60%·0.2는 "작은 효과"라는 **통계 관례**(논문 관행이지 법칙은 아님). 평가자 5명이면 범위 계산 자체가 불안정	사용 가능 194개 이상 수집 시

검증 결론 — 위치·질감·자연스러움은 이대로 평가지표로 써도 됩니다. 합격선마다 논문 표나 통계 계산으로 출처를 댈 수 있고, 현재 결과는 기준에서 크게 떨어져 있어 한계 때문에 결론이 뒤집히지 않습니다. **색상은 기준 자체는 쓸 수 있지만, 노출을 고정한 촬영 사진이 생기기 전까지는 "판정 불가"로 보고해야** 합니다. 발표에서는 "AR 메이크업 전용 공인 합격선은 없어서, 가장 가까운 공개 역치·벤치마크·통계로 정했다"고 설명하면 됩니다.

평가 코드와 출처

추가한 코드 (PC 저장소 `research/eval_matrix/`)

파일	하는 일
`criteria_v2.1.json`	이 문서의 합격선과 출처를 컴퓨터가 읽는 형태로 기록
`eval_matrix.py`	기존 측정 결과 파일만 읽어 4개 지표를 합격 / 불합격 / 판정 불가 / 미측정 / 기록만으로 출력. 부호 검정·필요 표본 수·피부 바닥값·평가자 단위 범위·이전 버전 비교를 자동 계산
`skin_floor.py`	사진 쌍마다 입 주변 피부 색 차이(색 판정 가능 여부)를 계산
`test_eval_matrix.py`	테스트 10개 (모두 통과)
`eval_matrix_v20.py`	이전 v2.0 기준 판정기 (비교용 보관)

실행 방법 (AR을 고친 뒤)

```
① python research/lip_reference/render_ar_offline.py        # 20쌍 AR 렌더
② python research/lip_reference/hw01_compare.py            # 색·질감 측정 →
research/data/hw01_compare.csv
③ python research/lip_reference/eval_lapa.py               # 입술 위치 측정 (입술 위치를 바꿨을 때)
④ python research/eval_matrix/eval_matrix.py --criteria research/eval_matrix/criteria_v2.1.json \
     --lapa research/data/reference/lapa/eval/baseline_landmarks.csv --lapa-prev <이전 버전 csv> \
     --lip research/data/hw01_compare.csv --floor research/eval_matrix/data/skin_floor.csv \
     --key research/data/ar_eval_public/naturalness_test/_v4_카탈로그색/key.csv --survey <설문 폴더> \
     --exclude 전진영 전진영5 --out research/eval_matrix/results/result_<날짜>_<커밋>.json
```

현재 출력 (최신 코드)

```
color        NOT_VALID   color_at 3.856 (≤1.8)  skin floor 2.90 ≥ 1.8 · color_beats_bare 15/20 p=0.021
pass
position     FAIL        lip_f1_sota 0.840 (≥0.887) · lip_no_regression not_measured
texture      FAIL        spread 8/20 · highlight 11/20 · ssim 6/20 (each ≥15)
naturalness  FAIL        accuracy 0.867, 90% CI 0.70–1.00 (upper <0.60) · score d 2.21
```

출처

- Paravina RD et al. (2015). Color difference thresholds in dentistry. *J Esthet Restor Dent* 27 Suppl 1:S1–S9. doi:10.1111/jerd.12149
- Lagouvardo P, Spyropoulou N, Polyzois G. (2018). Perceptibility and acceptability thresholds of simulated facial skin color differences. *J Prosthodont Res* 62(4):503–508
- Narayan K, VS V, Patel VM. SegFace: Face Segmentation of Long-Tail Classes. AAAI 2025. arXiv:2412.08647 (LaPa 표 1(a))
- Liu Y et al. (2020). A New Dataset and Boundary-Attention Semantic Segmentation for Face Parsing (LaPa, BASS). AAAI 2020
- Nightingale SJ, Farid H. (2022). AI-synthesized faces are indistinguishable from real faces and more trustworthy. *PNAS* 119(8). doi:10.1073/pnas.2120481119
- ITU-T Recommendation P.910 (2026-07). Subjective video quality assessment methods for multimedia applications
- Cohen J. (1988). *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. (효과크기 h, d의 "작은 효과" 0.2)
- Wang Z et al. (2004). Image quality assessment: From error visibility to structural similarity (SSIM). *IEEE TIP*
- Sharma G et al. (2005). The CIEDE2000 color-difference formula: implementation notes, supplementary test data. *Color Res Appl*